

SAÉ 3-01-EMS Recueil et analyse de données par échantillonnage ou plan d'expérience

Partie I – Synthèse de l'article

L'article « Exploring the assumption that commercial online nonprobability survey respondents are answering in good faith », publié en 2024 par Statistique Canada, aborde une problématique majeure dans le domaine des enquêtes en ligne. Il s'intéresse à la sincérité des répondants dans les échantillons non probabilistes commerciaux. Jusqu'à présent, la plupart des recherches sur ces échantillons mettaient l'accent sur le biais de sélection. Les auteurs adoptent une approche différente puisqu'ils remettent en question l'hypothèse selon laquelle les individus recrutés dans ces échantillons répondent honnêtement. Leur objectif est de comprendre si les erreurs observées dans ce type d'enquête sont uniquement liées à un manque de représentativité ou si elles proviennent aussi d'un manque de fiabilité dans les réponses fournies.

Pour mener leur étude, les chercheurs ont comparé deux types d'échantillons. Le premier correspond à des échantillons probabilistes, dans lesquels les participants sont sélectionnés aléatoirement à partir d'adresses postales selon la méthode Address-Based Sampling (ABS). Le second type d'échantillon concerne les échantillons volontaires non probabilistes, où les participants s'inscrivent volontairement pour répondre à des sondages, souvent contre rémunération. Ces échantillons représentent aujourd'hui plus de 80 % des enquêtes d'opinion réalisées aux États-Unis.

La recherche repose sur deux études complémentaires. La première est une étude de comparaison, menée sur six échantillons en ligne, dont trois probabilistes et trois non probabilistes. Chaque échantillon comprend environ 5 000 répondants. Les chercheurs ont confronté les résultats de ces sondages à 25 indicateurs de référence issus de sources officielles telles que l'American Community Survey ou le Current Population Survey. Ils ont ensuite mesuré les écarts entre les estimations et les valeurs réelles à l'aide de l'erreur absolue moyenne. Cette démarche a permis d'évaluer la précision globale des estimations mais aussi celle de certains sous-groupes, selon l'âge, le niveau d'éducation ou l'origine ethnique.

La seconde étude, appelée étude de suivi, visait à identifier la présence de réponses frauduleuses. Un questionnaire de quatorze questions a été soumis à 569 personnes issus d'un autre échantillon non probabiliste. Certaines questions étaient volontairement absurdes, par exemple « Êtes-vous autorisé à piloter un sous-marin nucléaire ? », afin de repérer les répondants qui donnaient des réponses incohérentes ou impossibles.

Les résultats obtenus montrent des différences importantes entre les deux types d'échantillons. Les échantillons probabilistes présentent une erreur moyenne d'environ 3 %, tandis que les échantillons non probabilistes atteignent en moyenne 6,8 %. Les erreurs les plus marquées concernent les jeunes de 18 à 29 ans et les répondants s'identifiant comme hispaniques, dont les écarts dépassent 10 points de pourcentage. Les chercheurs ont également observé que de nombreux répondants des échantillons non probabilistes affirmaient percevoir plusieurs aides sociales à la fois, une situation très rare dans la population réelle. Ces observations indiquent que certaines réponses sont fausses, exagérées.

L'étude de suivi confirme cette hypothèse. Une proportion importante de répondants issus d'échantillons non probabilistes a donné des réponses manifestement impossibles. Près d'un quart des participants s'identifiant comme hispaniques ont, par exemple, affirmé être qualifiés pour conduire un sous-marin nucléaire. Ce phénomène, appelé « bogus responding », correspond à des réponses fournies sans réflexion ou simplement pour obtenir une récompense. Même après avoir éliminé les cas les plus suspects, les erreurs des échantillons non probabilistes restent élevées.

La différence essentielle entre échantillons probabilistes et échantillons non probabilistes repose donc sur la qualité et la fiabilité des données recueillies. Les échantillons probabilistes assurent une sélection aléatoire, une pondération rigoureuse et une représentativité mesurable. À l'inverse, les échantillons non probabilistes reposent sur le volontariat, ce qui rend le biais de sélection incontrôlable et favorise la présence de répondants inattentifs ou mal intentionnés.

En conclusion, l'article remet en question la fiabilité des échantillons non probabilistes utilisés dans les enquêtes commerciales en ligne. Les auteurs démontrent que les erreurs de mesure liées à des réponses mensongères ou incohérentes représentent un problème aussi important que le manque de représentativité. Les méthodes statistiques d'ajustement ne suffisent pas à corriger ces erreurs lorsque les données initiales sont fausses. Cette étude incite donc les statisticiens et les entreprises de sondage à mettre en place des procédures de détection des répondants non sincères et à renforcer la transparence des méthodes employées pour garantir la qualité des données.

Partie II – Analyse critique et proposition d'analyse complémentaire

L'article de Stat Canada constitue une contribution importante pour la méthodologie des enquêtes en ligne. Il aborde la question de la fiabilité des données issues d'échantillons non probabilistes, un sujet particulièrement pertinent pour les spécialistes en science des données. L'étude montre un problème souvent négligé, celui des répondants frauduleux qui compromettent la qualité des résultats au-delà du simple biais de sélection. De plus, les sondages en ligne sont omniprésents et influencent des décisions économiques, politiques ou marketing. Dans ce contexte, réfléchir à la qualité des données utilisées dans ces enquêtes apparaît indispensable.

L'apport principal de cette recherche est d'avoir établi un lien clair entre les erreurs observées et le comportement des répondants. Les auteurs montrent que certaines catégories de la population, notamment les jeunes et les personnes se déclarant hispaniques, produisent des réponses incohérentes. L'étude souligne également les limites des modèles statistiques utilisés pour corriger les biais d'échantillonnage. Si les variables de pondération sont elles-mêmes fausses, les ajustements effectués perdent toute valeur. Cette conclusion est très importante pour les professionnels de la donnée, car elle rappelle que la qualité statistique dépend avant tout de la fiabilité des observations de départ.

Cependant, l'article présente plusieurs limites méthodologiques. Les analyses portent uniquement sur des échantillons commerciaux américains, ce qui empêche de généraliser les résultats à d'autres contextes. De plus, la détection des répondants frauduleux repose surtout sur des questions extrêmes ou absurdes. Si cette méthode est efficace pour repérer les cas les plus flagrants, elle ne permet pas d'identifier les comportements plus discrets, comme les réponses données au hasard. L'article aurait gagné en précision s'il avait intégré des tests de cohérence plus variés ou une étude qualitative visant à comprendre les motivations des faux répondants. Les nombreux tableaux sont parfois denses et difficiles à interpréter pour un lecteur non expert. Une synthèse graphique plus claire aurait facilité la compréhension globale.

Les sources mobilisées dans cette recherche sont néanmoins solides. Les auteurs fondent leur analyse sur une base théorique solide en méthodologie d'enquête, complétée par des données officielles provenant de sources publiques américaines. Ce choix confère une crédibilité importante à leurs comparaisons. Cependant, l'absence de données issues d'autres pays limite la portée internationale de l'étude.

L'article présente une valeur durable dans le domaine de la statistique appliquée. Le recours aux échantillons en ligne continuant de croître, les problématiques soulevées autour de la fraude, de la sincérité et de la fiabilité des réponses resteront pertinentes pendant plusieurs années. Il est toutefois probable que l'évolution rapide des technologies comme l'IA permettra de détecter automatiquement des comportements suspects, modifiant ainsi les méthodes de contrôle évoquées.

Pour pousser l'analyse plus loin, il serait intéressant de réaliser une étude intégrant différents mécanismes de vérification automatique, comme des questions de contrôle de la concentration ou des questions pièges aléatoires. Une comparaison internationale permettrait aussi de déterminer si le phénomène de fausses réponses est propre au contexte américain ou s'il s'observe plus largement. Enfin, pour réactualiser l'analyse, on pourrait répéter la même étude dans quelques années afin d'observer l'évolution de la qualité des réponses dans le temps. Cette démarche permettrait de vérifier si les plateformes de sondage ont réellement amélioré leurs méthodes de contrôle. On pourrait également combiner un échantillon probabiliste avec un échantillon non probabiliste. Cette approche mixte aiderait à réduire les biais et à améliorer la qualité des données, sans augmenter trop les coûts.

